

1研究背景と研究目的

1.1研究背景

- ・実世界にはあらゆる最適化
例) 工学設計・ロボット制御・Neural Architecture Search など

1.1.1 最適化[1]

- ・対象を限定せず近似解を求める
→メタヒューリスティック
ex)GA (genetic algorithm)

- ・目的関数の計算を何回も行う。

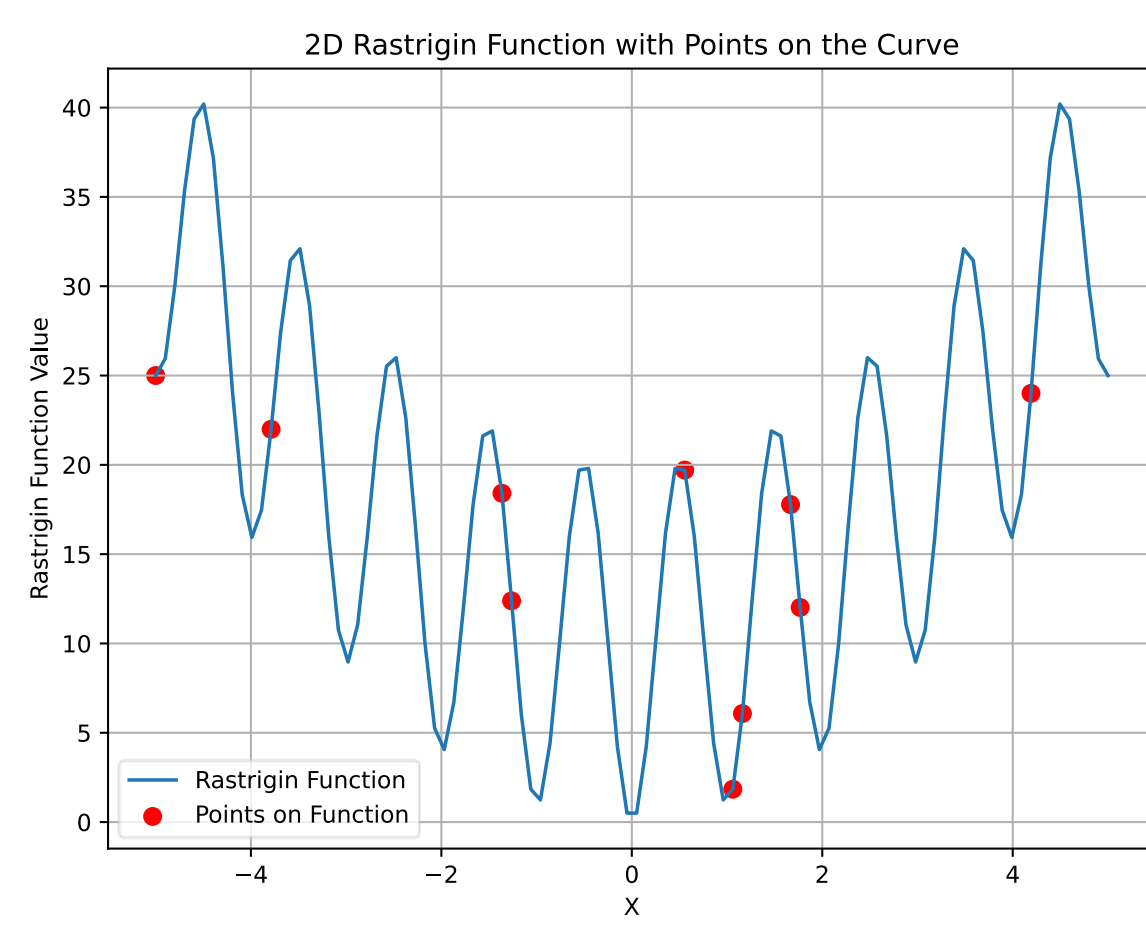


図1:Objective function

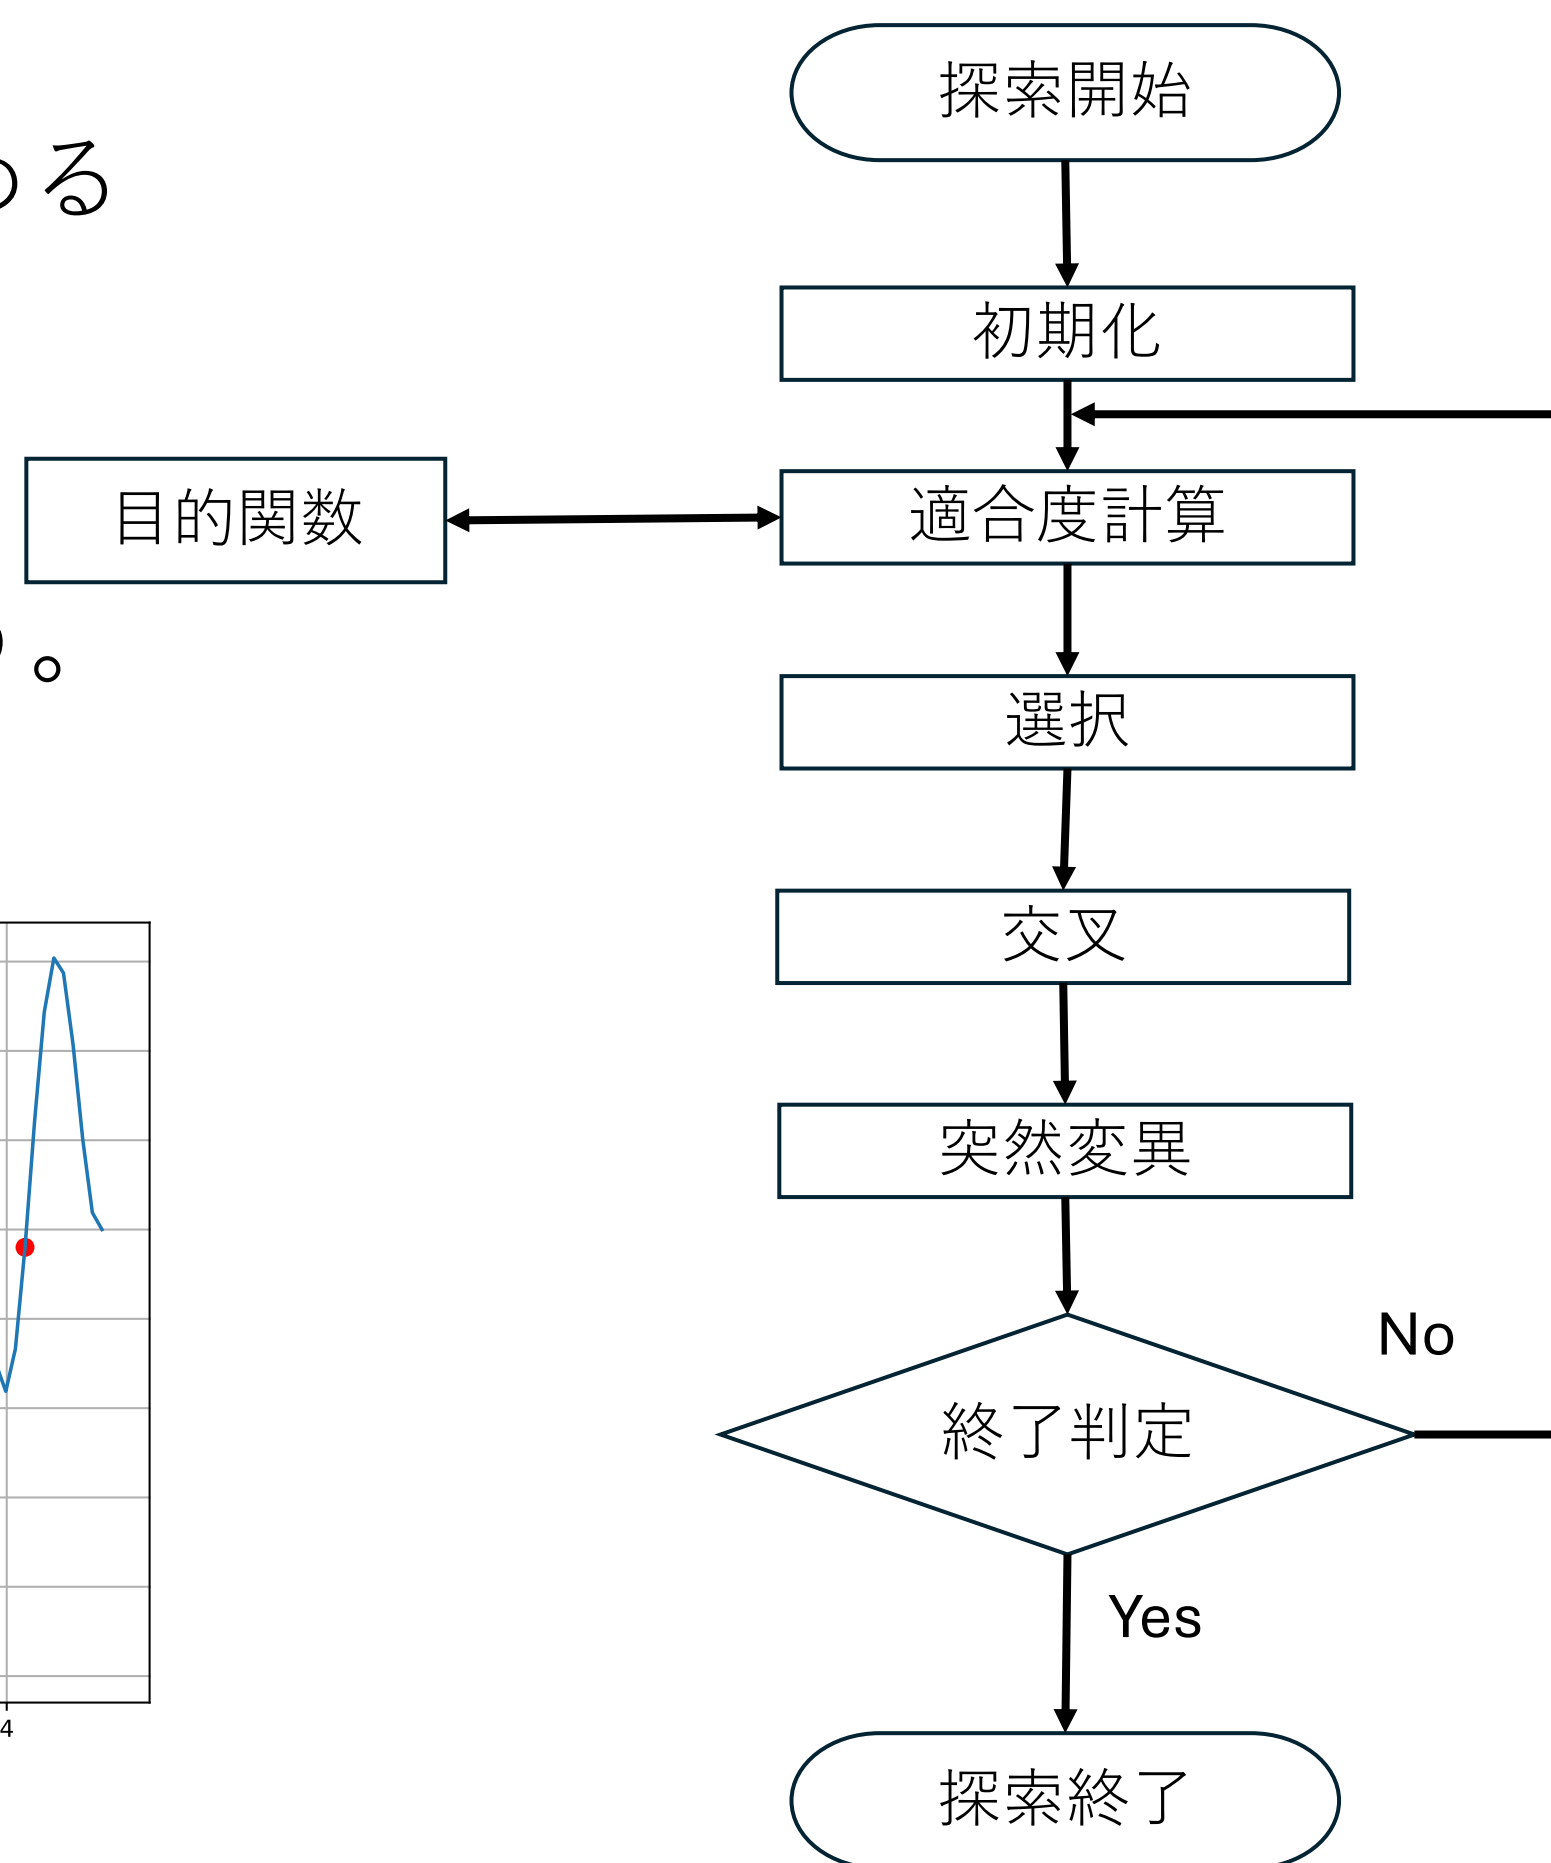


図2:GAのアルゴリズム

1.1.2 Surrogate model[2]

- ・適応度の計算が困難→代理モデルの生成[3]
- ・図 2 目的関数→Surrogate modelの近似解

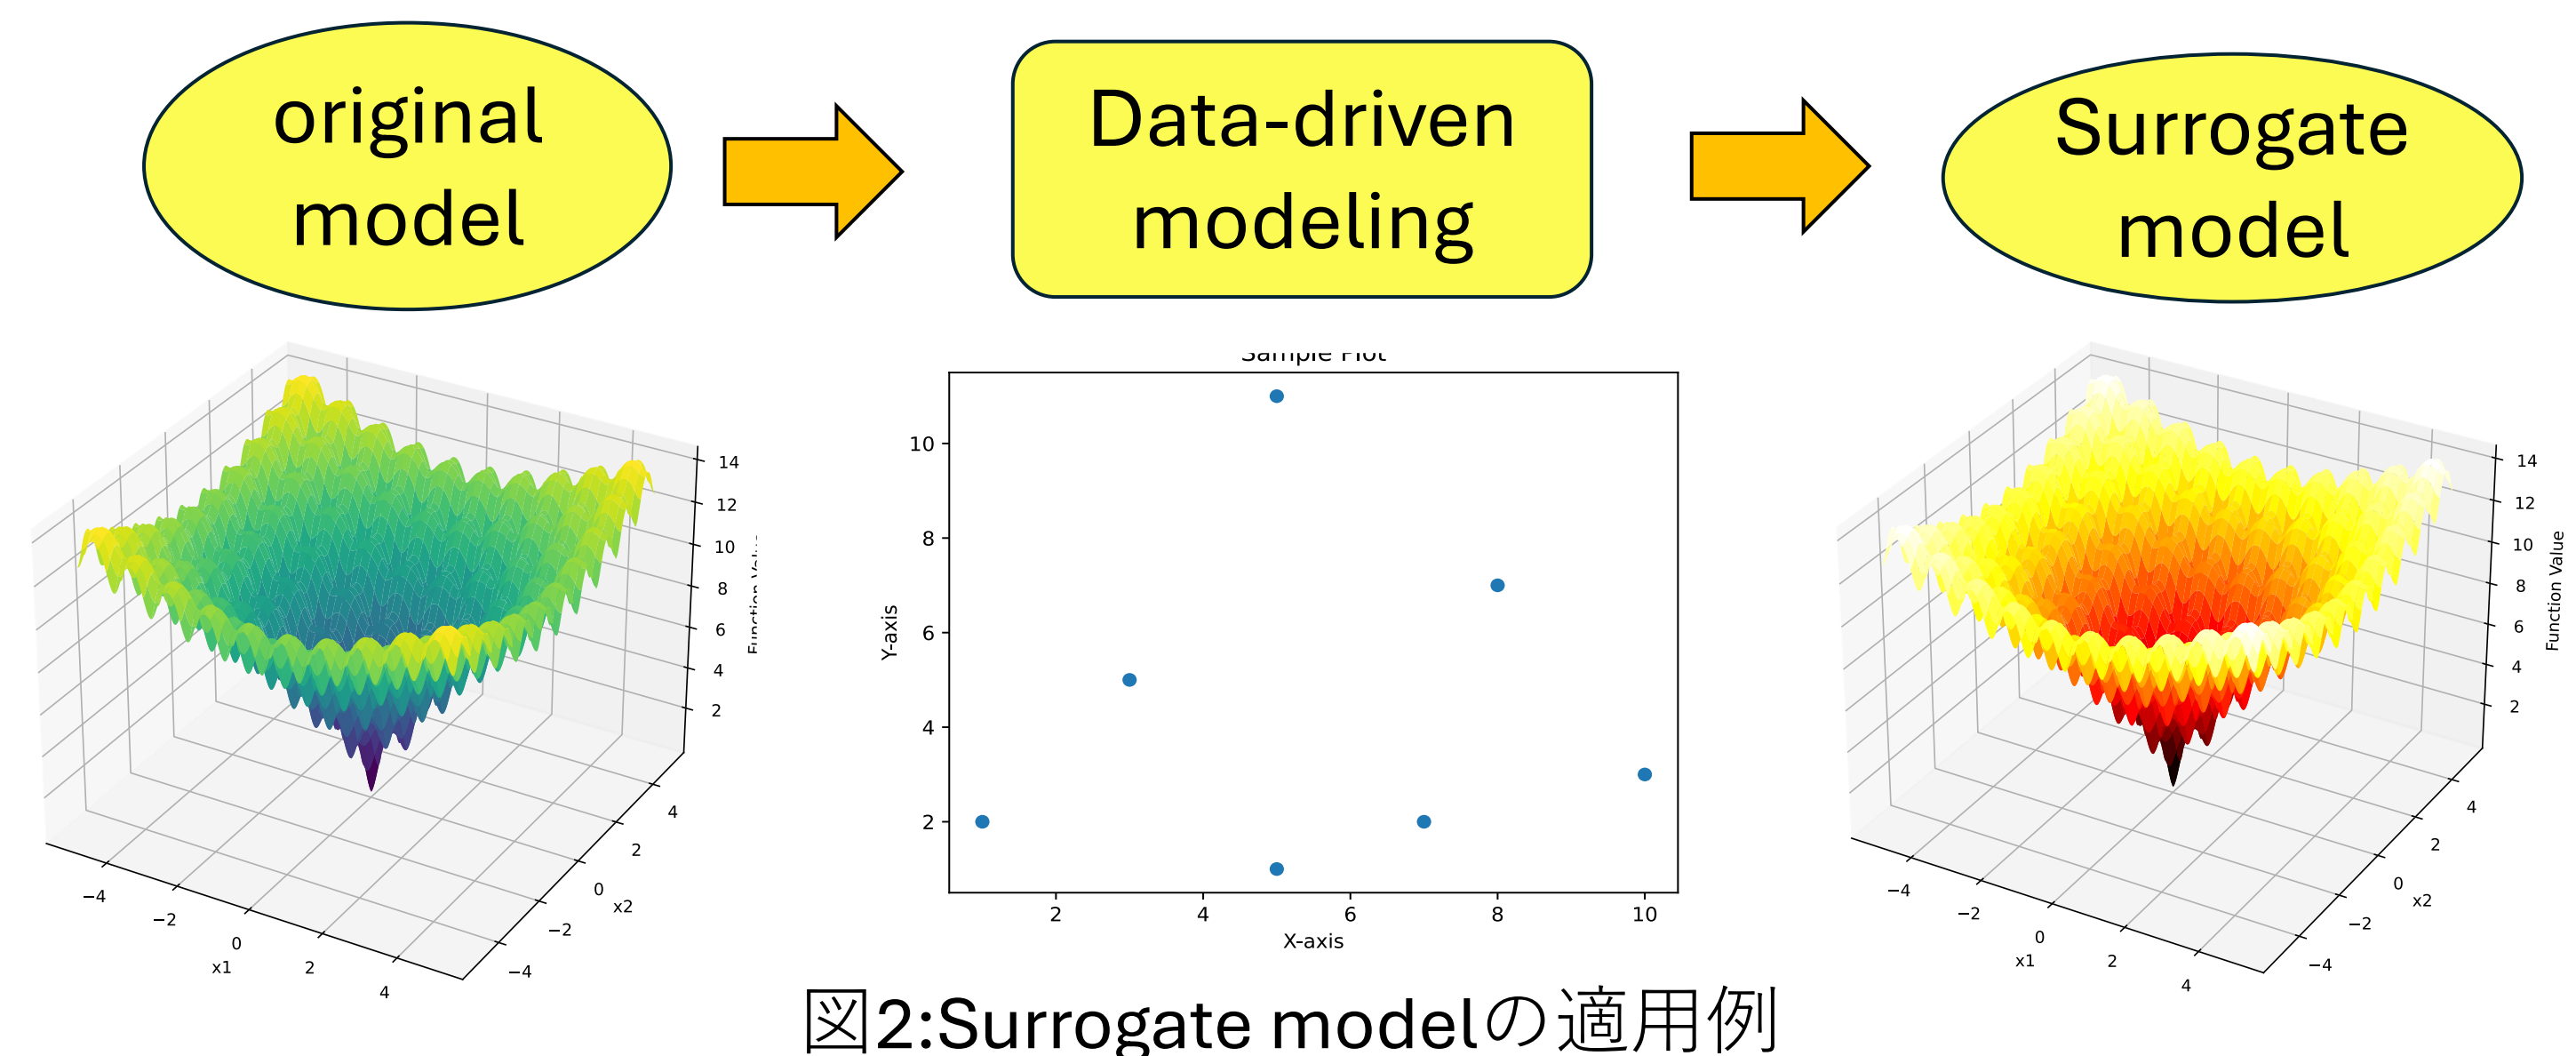


図2:Surrogate modelの適用例

1.1.3 従来研究の問題点

- ・目的関数の解空間は**高次元**
 - ・低次元への分割（効率的な探索）
- 変数間の**依存関係**が重要

表1:ランダムに分割

次元数	分割なし	分割あり(ランダム)
d=50	494.17	9198.59

1.2研究目的

グラフニューラルネットワークを用いて高次元な関数の解空間を低次元な部分空間に分割して探索することで探索性能の向上

1.2.1 Graph Neural Network

グラフ構造をニューラルネットワーク[4]
画像認識・自然言語処理・社会モデルなどに応用




図3:Graph Neural Network

2研究の進捗

2.1提案手法

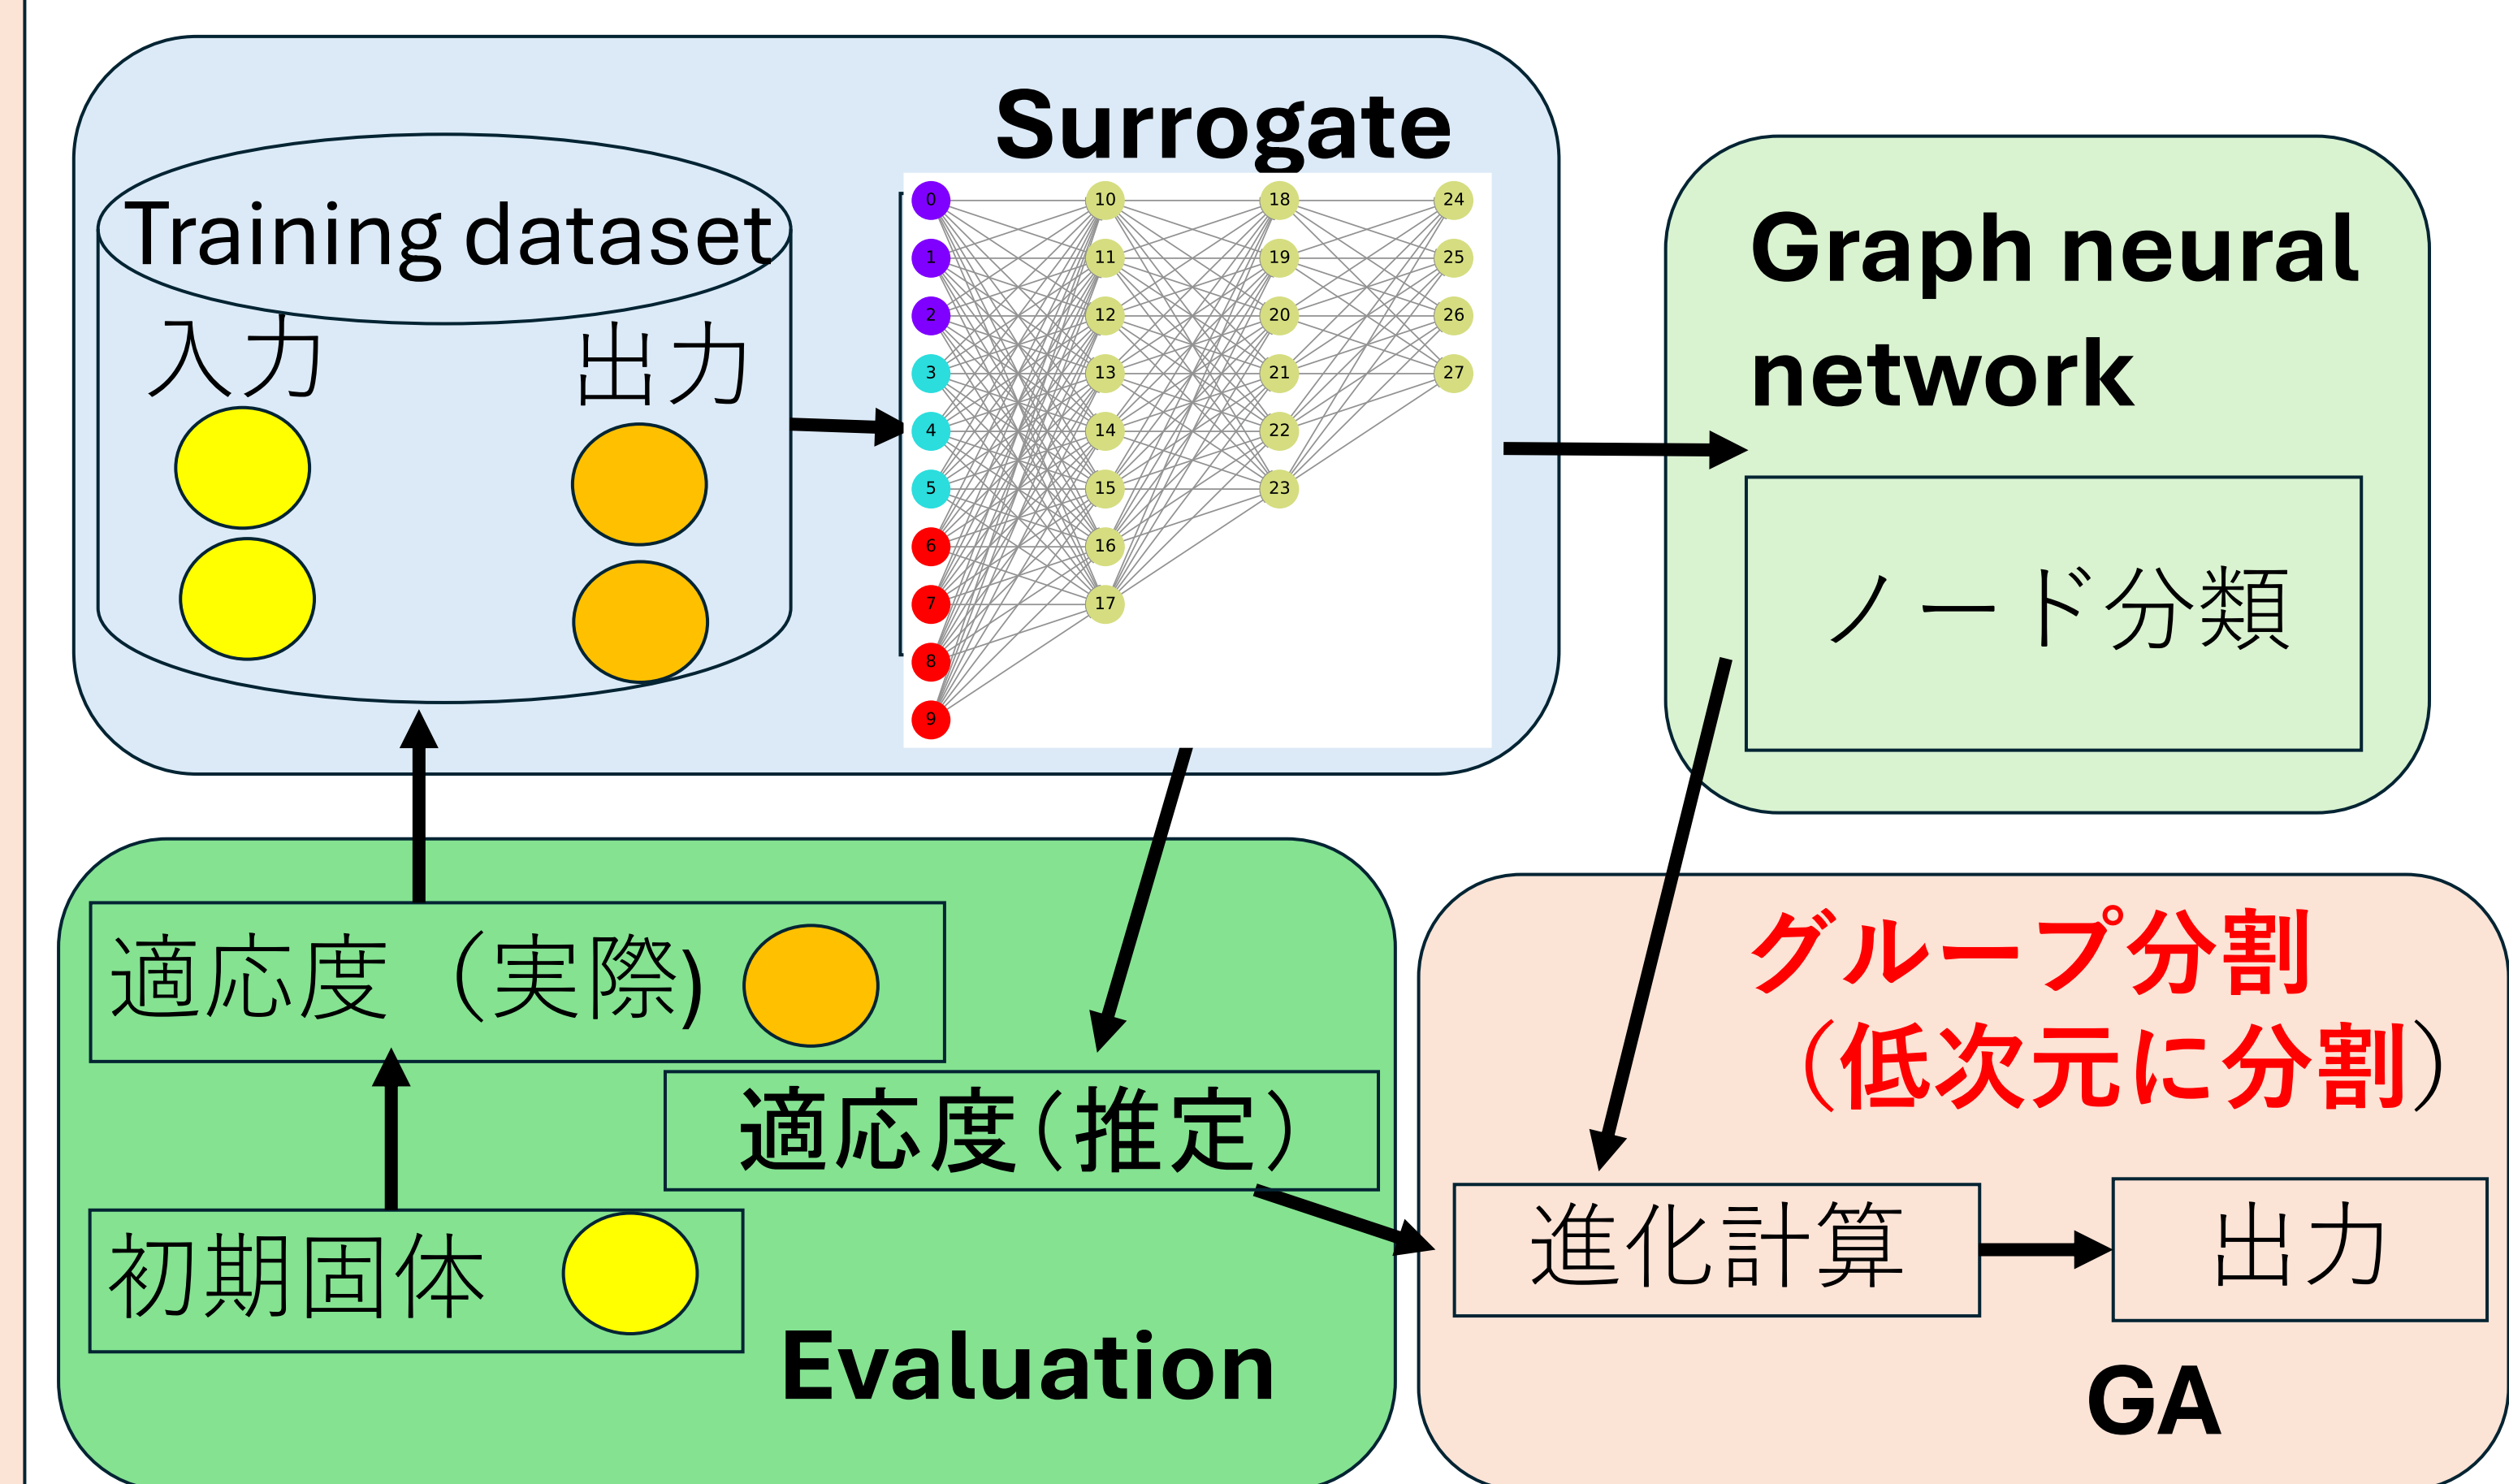


図4:提案手法の全体モデル

2.2研究の進捗

2.2.1実験環境

Rosenbrock + Dixon + Rosenbrock




図5:Rosenbrock




図6:Dixon Function

$$f(x) = \sum_{i=1}^d \left[100(x_{i+1} - x_i^2)^2 + (x_i - 1)^2 \right] \quad (1)$$

- ・ x_{i+1} と x_i が乗算される
- ・ 次の変数に依存関係がある

$$f(x) = \sum_{i=1}^{d-1} (x_1 - 1)^2 + \sum_{i=2}^d i(2x_i^2 - x_{i-1})^2 \quad (2)$$

- ・ x_{i-1} と x_i に依存関係がある

2.2.2実験結果

表2:実験結果

次元数	分割なし	分割あり (GNN)	分割あり (理想な分割)
d=150	9002.44	2940.64	353.11

分割の精度→80%
GNNでの有用性

2.3 研究計画

- ・グラフニューラルネットワークの教師なしクラスタリング

通常のクラスタリングでは困難（ノードの位置）
Auto Encoderを用いたクラスタリング[5]
→グラフニューラルネットワークの精度向上

- ・目的関数の複雑化
回転が加わるベンチマーク関数
最先端の手法との比較

3参考文献

- [1] Y. Liu, et, "Infill Criterion Ensemble in Multi Objective Evolutionary Algorithm for Mixed Variable Problems." 2024
- [2] X. Wang et, "A Graph Neural Network Assisted Evolutionary Algorithm for Expensive Multi Objective Optimization." 2024
- [3] Kocijan, J. et. Surrogate modelling for the forecast of Seveso-type atmospheric pollutant dispersion.
- [4] Wu, Z., et., (2020). A comprehensive survey on graph neural networks. IEEE transactions on neural networks and learning systems, 32(1), 4-24.
- [5] Mao, Q et, "Clustering driven multi-hop graph at tention network for speaker Diarization." 2023