

1研究背景と研究目的

1.1研究背景

実世界にはあらゆる最適化（工学設計など）
メタヒューリスティックなど近似解

1.1.1 最適化

実世界のシステムに最適化
→対象を限定せず近似解

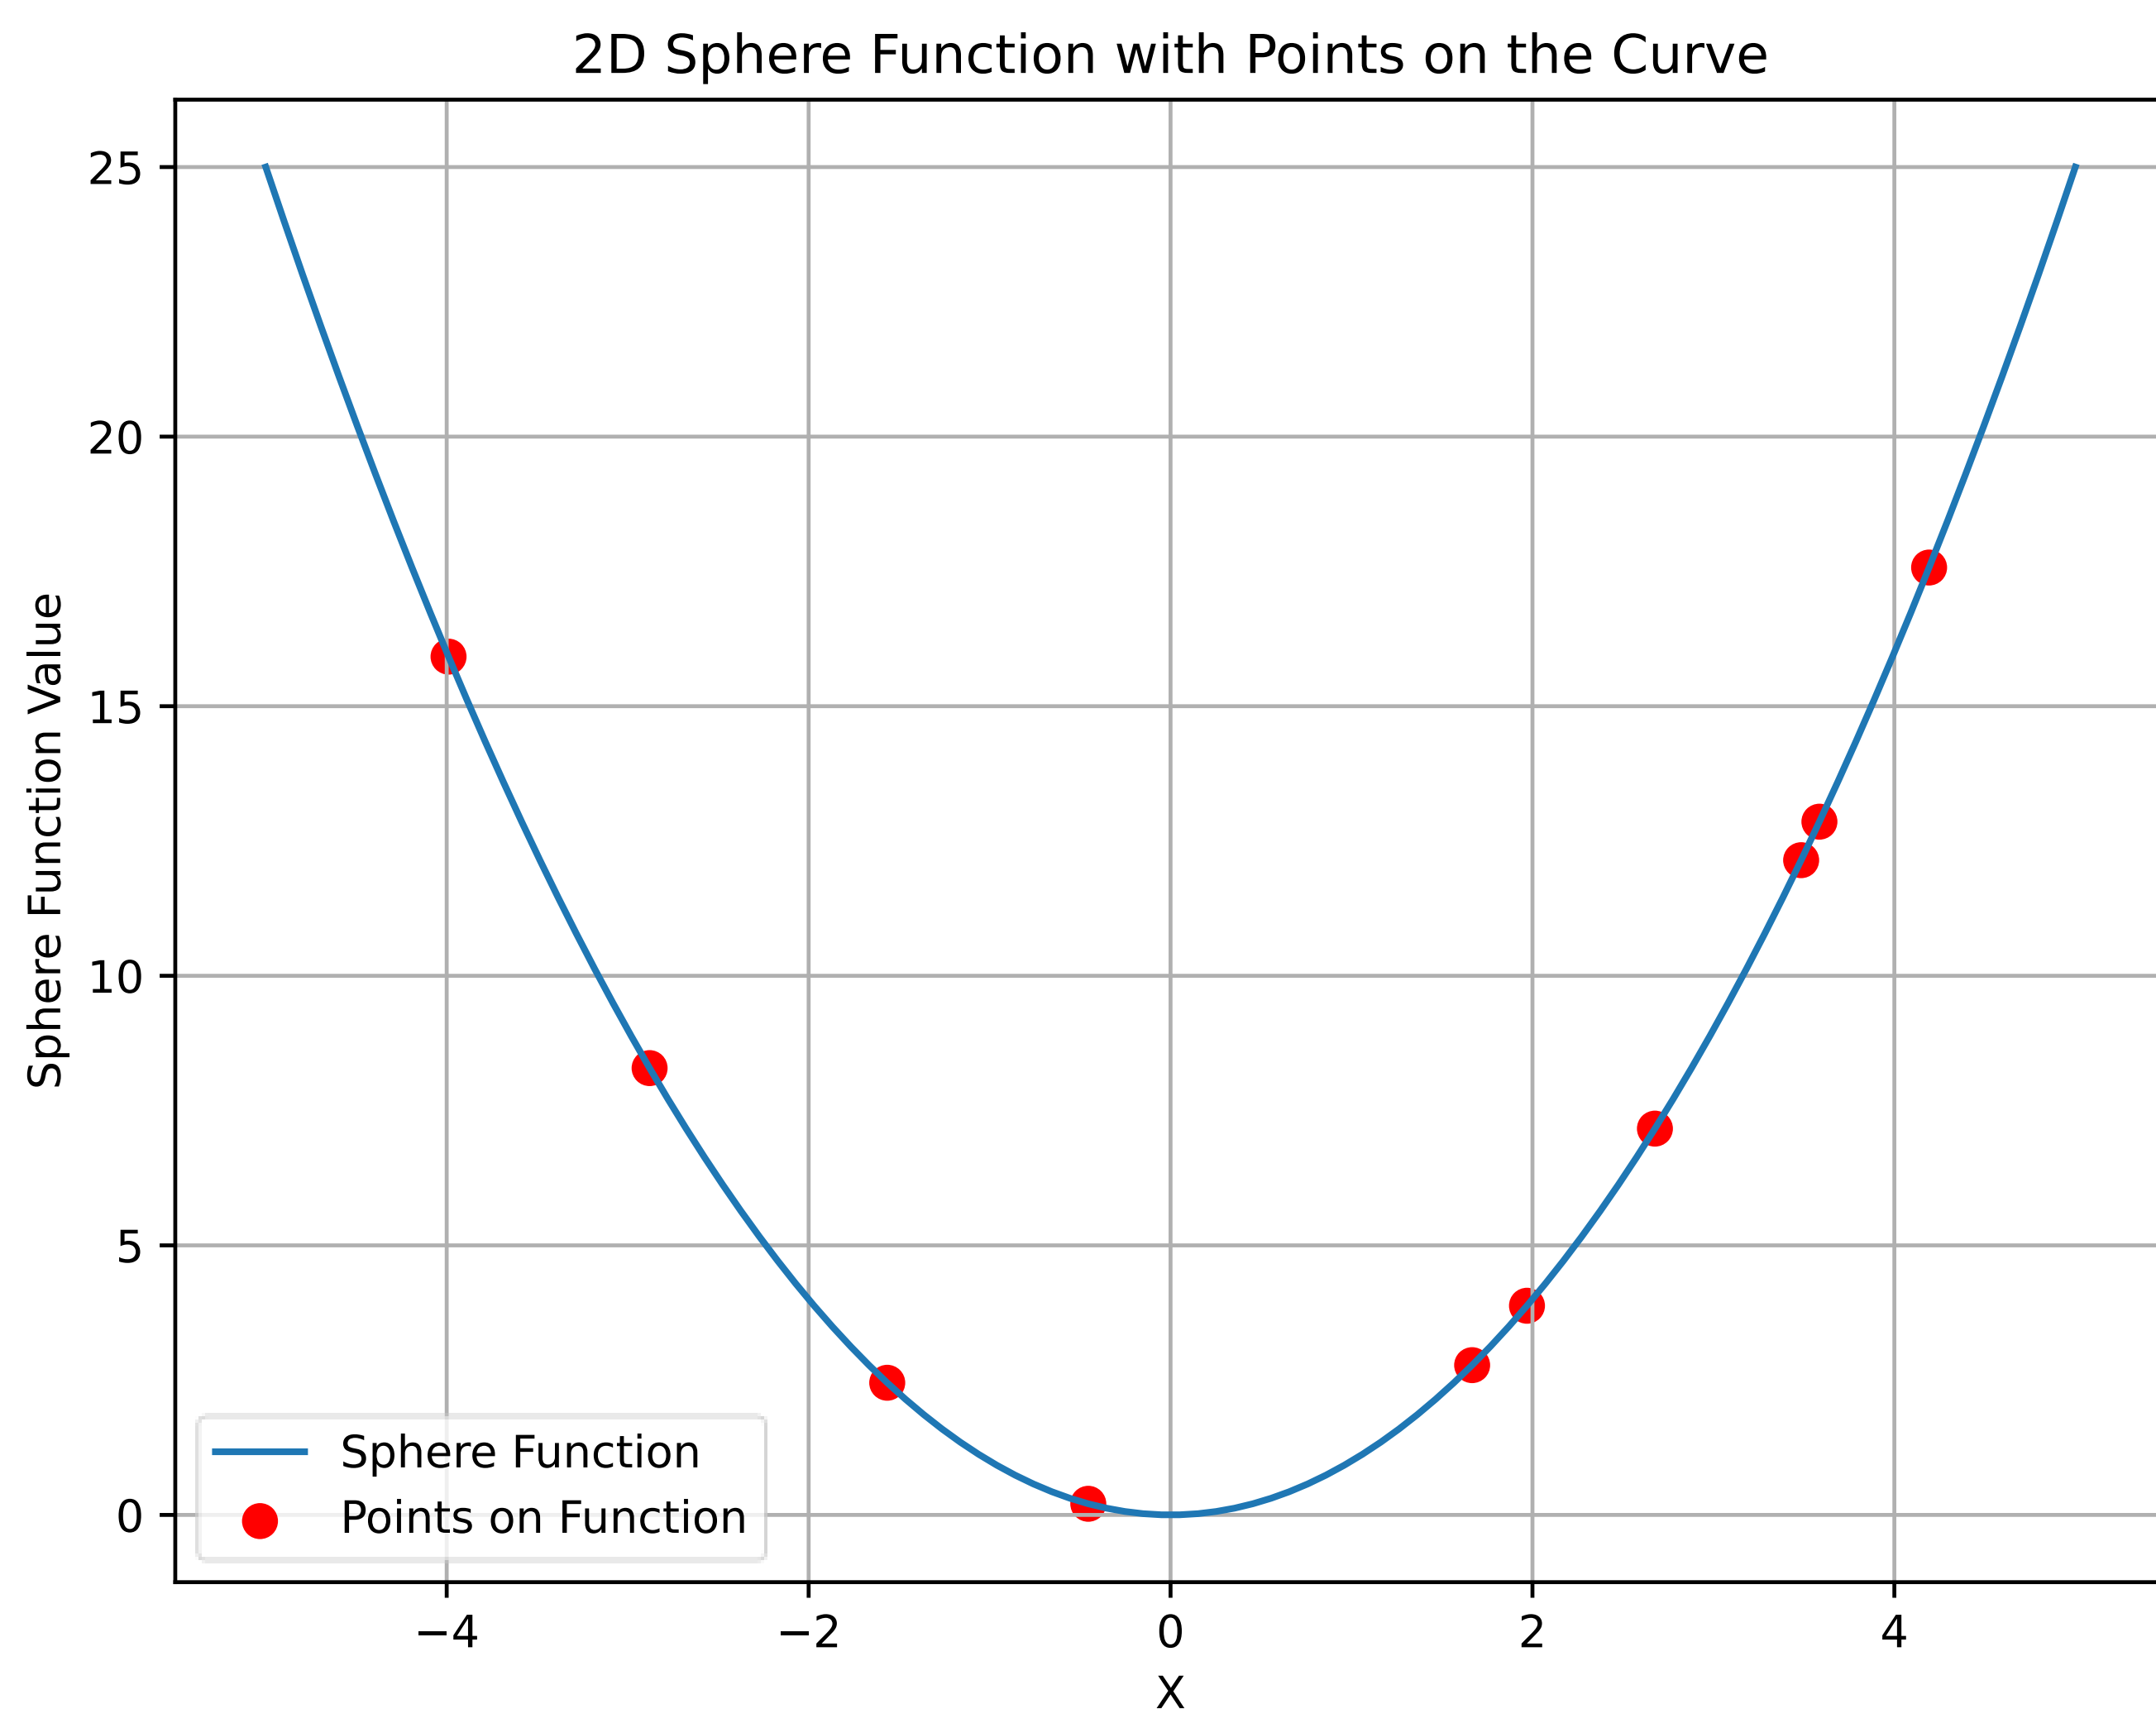


図1:Sphere function

1.1.2 Surrogate model

適応度の計算が困難→代理モデルの生成[1]




図2:Surrogate modelの適用例

1.1.3 Graph Neural Network

グラフ構造をニューラルネットワーク[2]




図3:Graph Neural Networkの適用例

⇒目的関数は高次元で探索が困難

1.2研究目的

- ・グラフニューラルネットワークを用いて高次元関数を低次元ごとに分割して探索

2研究の進捗

2.1提案手法

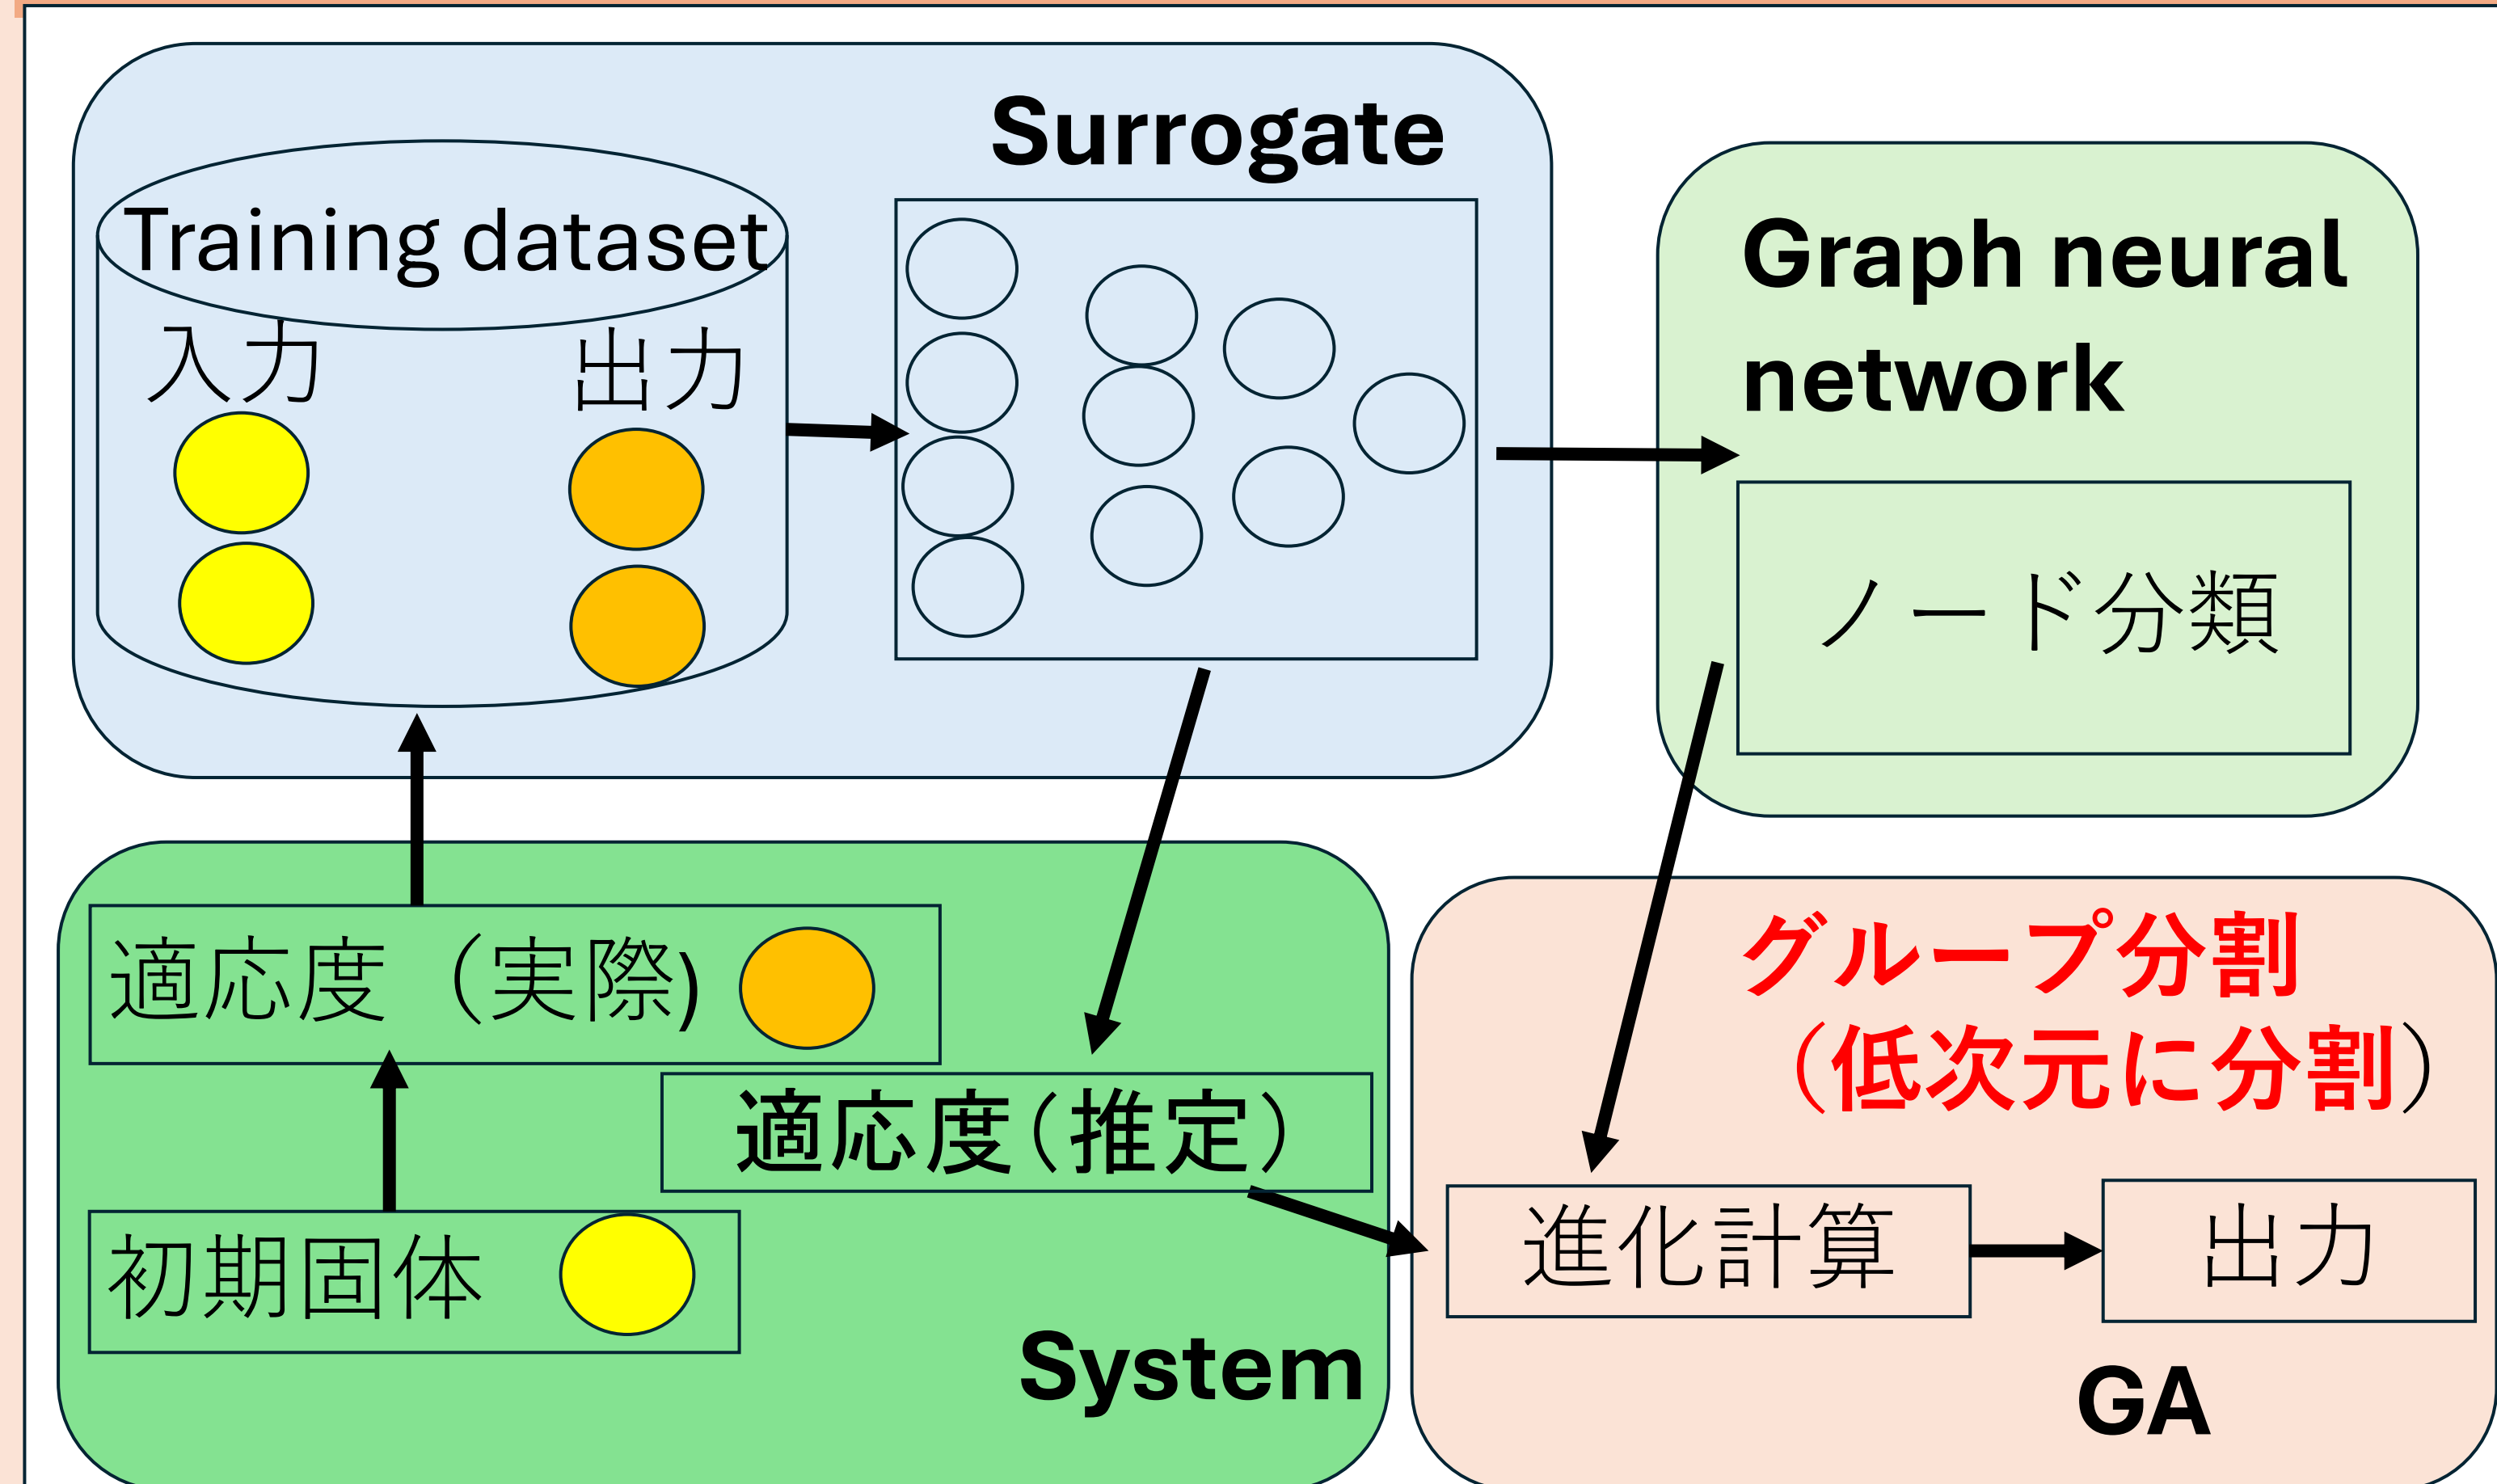


図4:提案手法の全体モデル

2.2研究の進捗

2.2.1実験環境

Rosenbrock(50次元)+Dixon(50次元)+Rosenbrock(50次元)




図5:Rosenbrock




図6:Dixon Function

$$f(x) = \sum_{i=1}^d \left[100(x_{i+1} - x_i^2)^2 + (x_i - 1)^2 \right] \quad (1)$$

$$f(x) = \sum_{i=1}^{d-1} (x_1 - 1)^2 + \sum_{i=2}^d i(2x_i^2 - x_{i-1})^2 \quad (2)$$

2.2.2実験結果

表1:実験結果

分割なし	分割あり
2.19e+09	1.63e+09

2.3 研究計画

- ・教師なしのクラスタリング
- ・グラフニューラルネットワーク精度向上

3参考文献

- [1]Kocijan, J., Stefan, I.J., Hvala, N., Zlata, P.M., d.o.o., B.M., Kocijan, J., Perne, M., Mlakar, P., Grašič, B., Marija, ., Božnar, Z., Kocijan, J., & d.o.o, M.Z. Surrogate modelling for the forecast of Seveso-type atmospheric pollutant dispersion.
[2] Wu, Z., Pan, S., Chen, F., Long, G., Zhang, C.Philip, S. Y. (2020). A comprehensive survey on graph neural networks. IEEE transactions on neural networks and learning systems, 32(1), 4-24.

1研究背景と研究目的

1.1研究背景

実世界にはあらゆる最適化（工学設計など）
メタヒューリスティックなど近似解

1.1.1 最適化

実世界のシステムに最適化
→対象を限定せず近似解




図1:Sphere function

1.1.2 Surrogate model

適応度の計算が困難→代理モデルの生成[1]

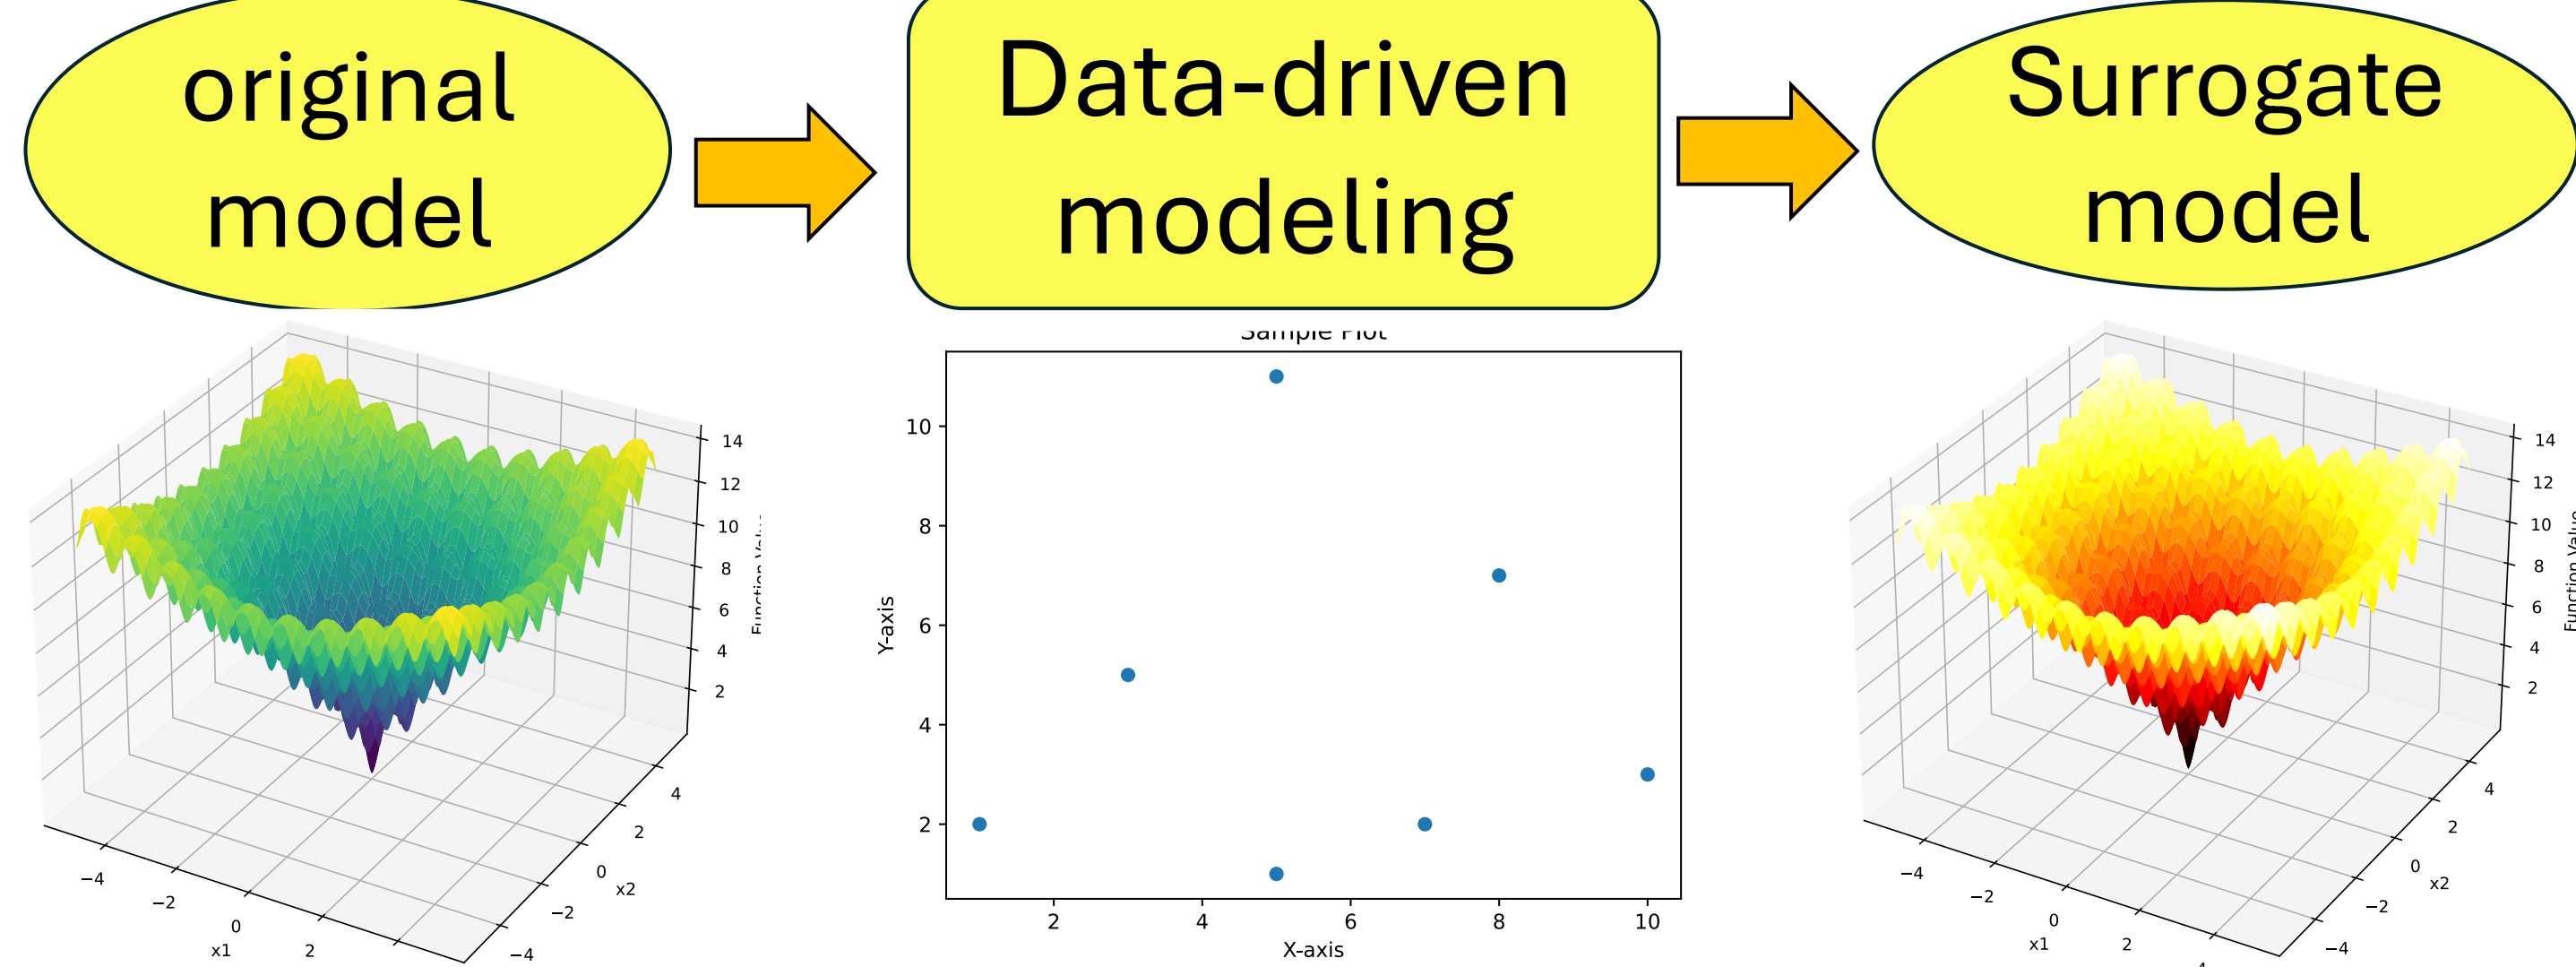


図2:Surrogate modelの適用例

→目的関数は高次元で探索が困難

1.2研究目的

- ・グラフニューラルネットワークを用いて
高次元関数を低次元ごとに分割して探索

1.2.1 Graph Neural Network

グラフ構造をニューラルネットワーク[2]




図3:Graph Neural Networkの適用例

2研究の進捗

2.1提案手法

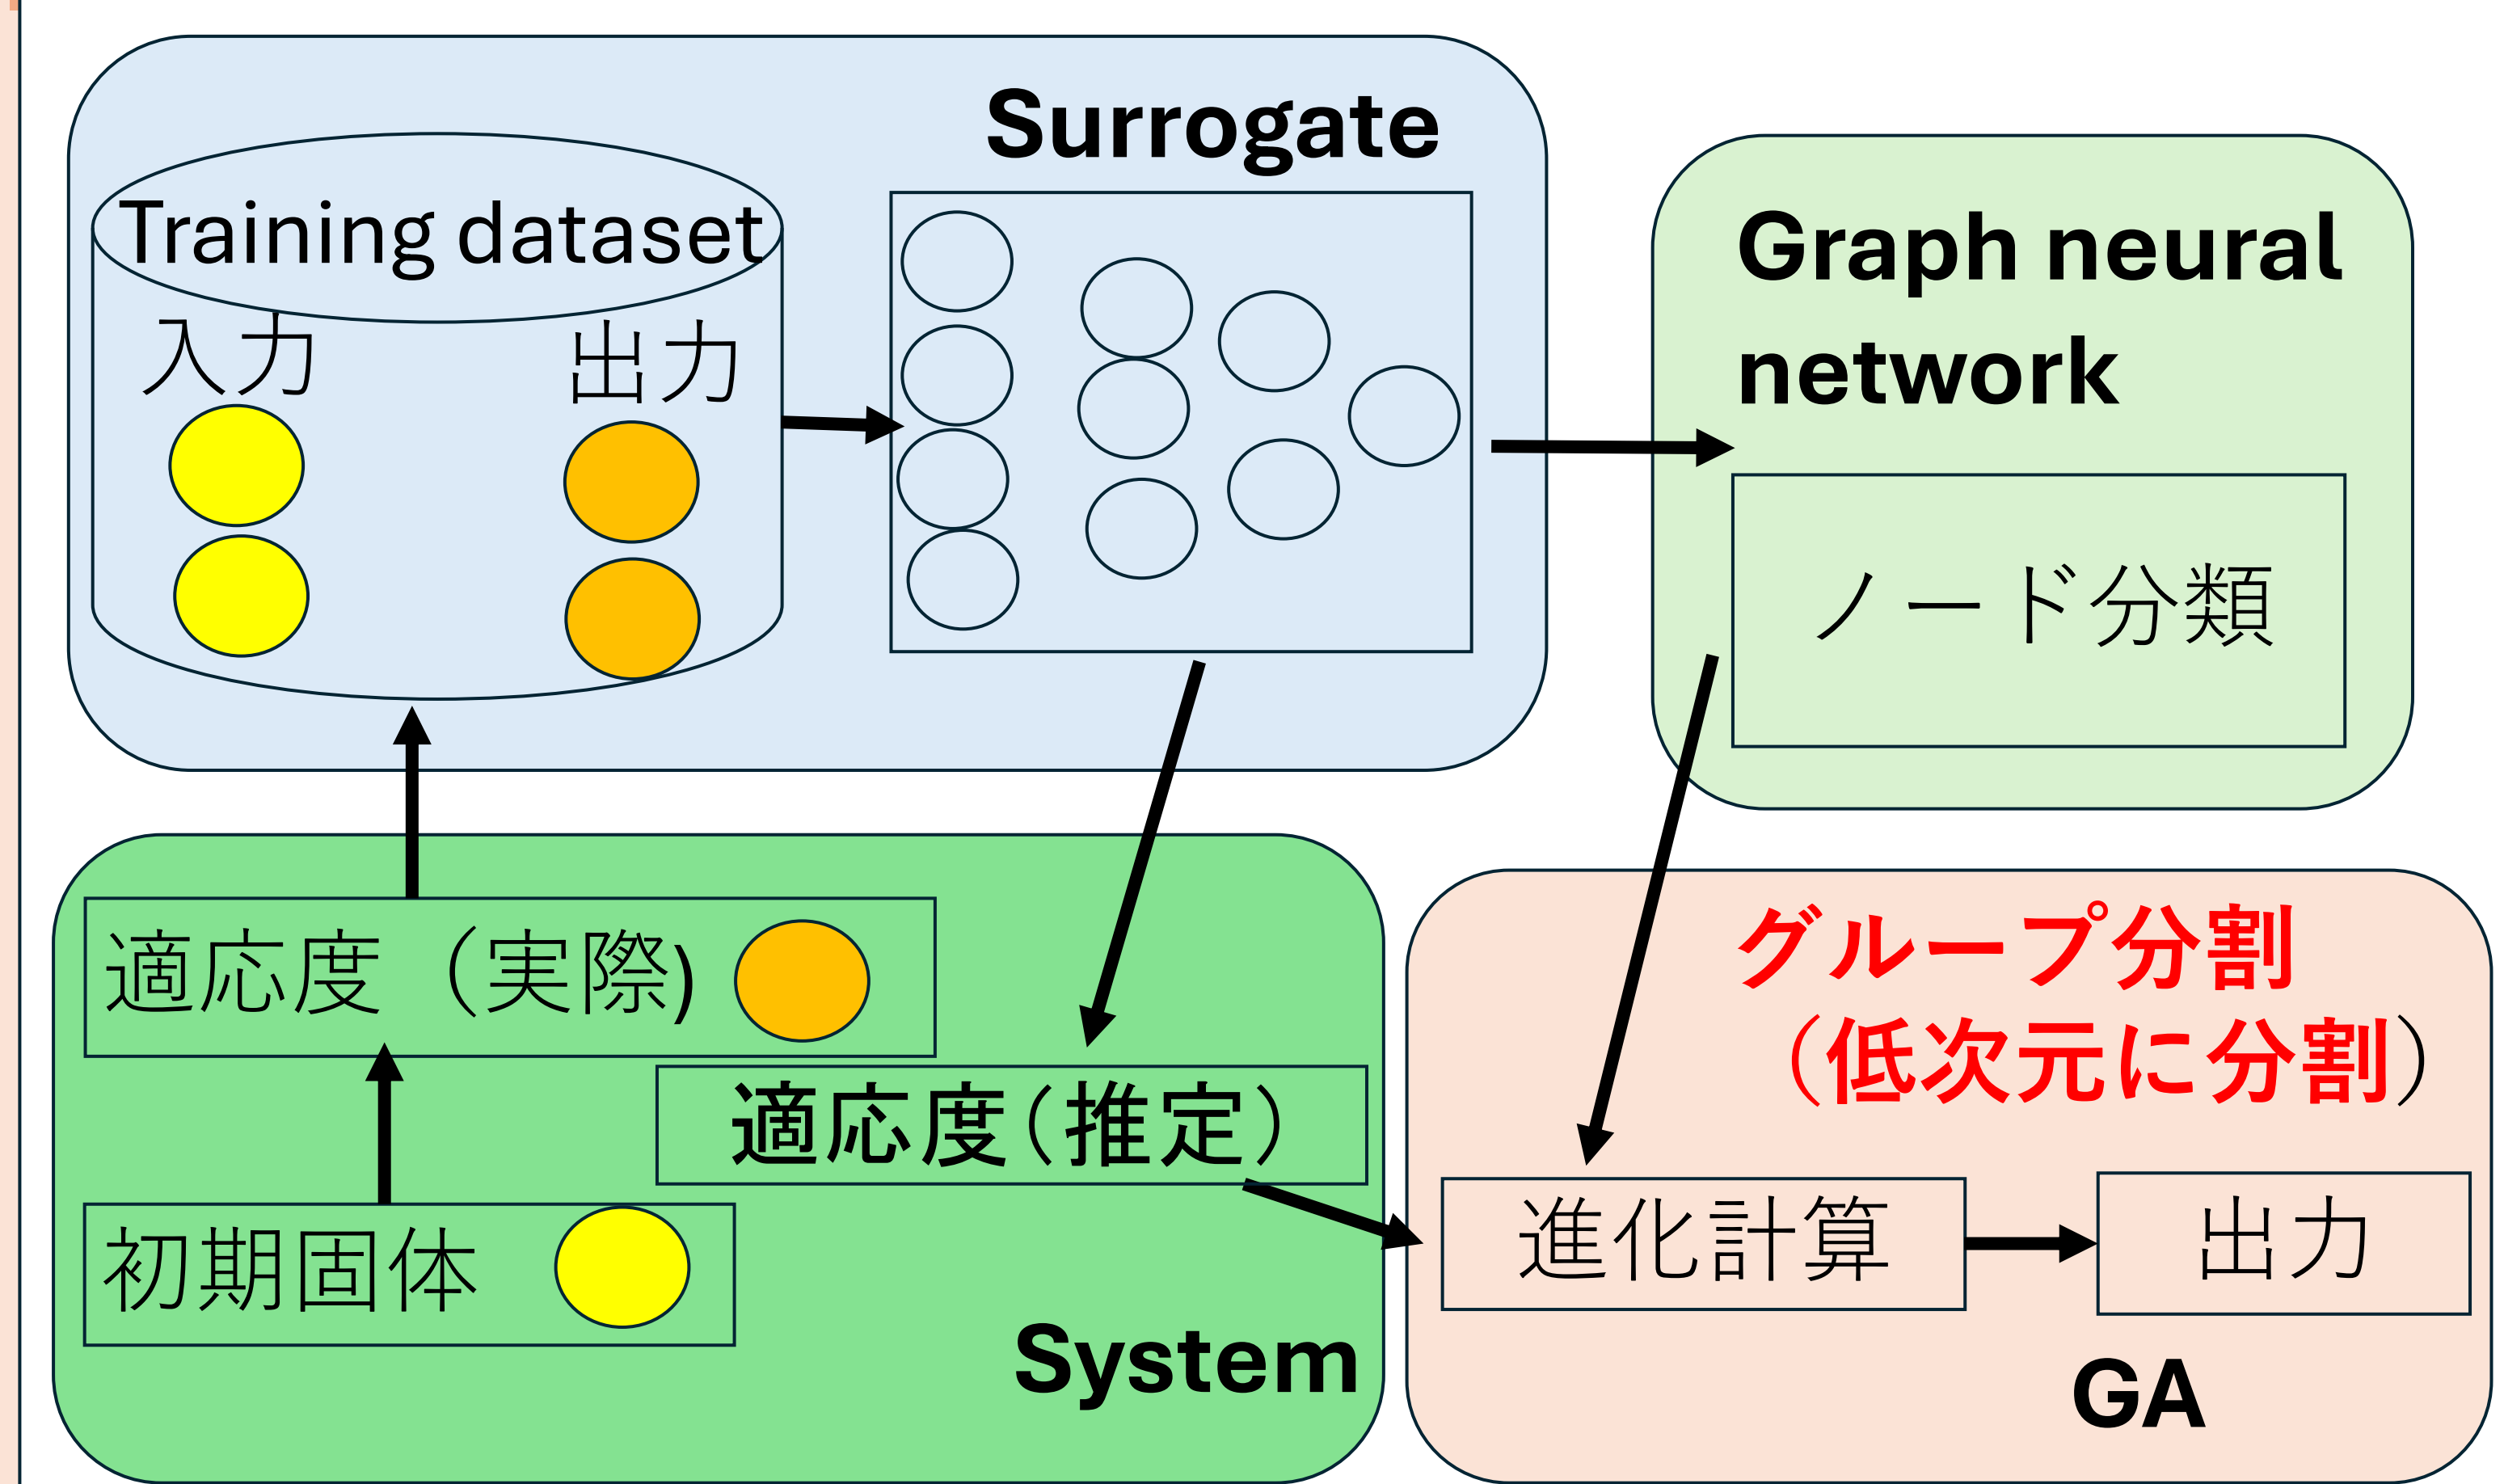


図4:提案手法の全体モデル

2.2研究の進捗

2.2.1実験環境

Rosenbrock(50次元)+Dixon(50次元)+Rosenbrock(50次元)




図5:Rosenbrock




図6:Dixon Function

$$f(x) = \sum_{i=1}^d \left[100(x_{i+1} - x_i^2)^2 + (x_i - 1)^2 \right] \quad (1)$$

$$f(x) = \sum_{i=1}^{d-1} (x_1 - 1)^2 + \sum_{i=2}^d i(2x_i^2 - x_{i-1})^2 \quad (2)$$

2.2.2実験結果

表1:実験結果

分割なし	分割あり
2.19e+09	1.63e+09

2.3 研究計画

- ・教師なしのクラスタリング
- ・グラフニューラルネットワーク精度向上

3参考文献

- [1]Kocijan, J., Stefan, I.J., Hvala, N., Zlata, P.M., d.o.o., B.M., Kocijan, J., Perne, M., Mlakar, P., Grašič, B., Marija, ., Božnar, Z., Kocijan, J., & d.o.o, M.Z. Surrogate modelling for the forecast of Seveso-type atmospheric pollutant dispersion.
[2] Wu, Z., Pan, S., Chen, F., Long, G., Zhang, C.Philip, S. Y. (2020). A comprehensive survey on graph neural networks. IEEE transactions on neural networks and learning systems, 32(1), 4-24.

1研究背景と研究目的

1.1研究背景

実世界にはあらゆる最適化（工学設計など）
メタヒューリスティックなど近似解

1.1.1 最適化

実世界のシステムに最適化
→対象を限定せず近似解




図1:Sphere function

1.1.2 Surrogate model

適応度の計算が困難→代理モデルの生成[1]




図2:Surrogate modelの適用例

1.1.3 従来研究の問題点

目的関数は**高次元**
低次元への分割→**依存関係**が重要

分割なし	分割あり
<u>1.14e+08</u>	5.42e+08

1.2研究目的

- ・グラフニューラルネットワークを用いて高次元関数を低次元ごとに分割して探索

1.2.1 Graph Neural Network

グラフ構造をニューラルネットワーク[2]

2研究の進捗

2.1提案手法

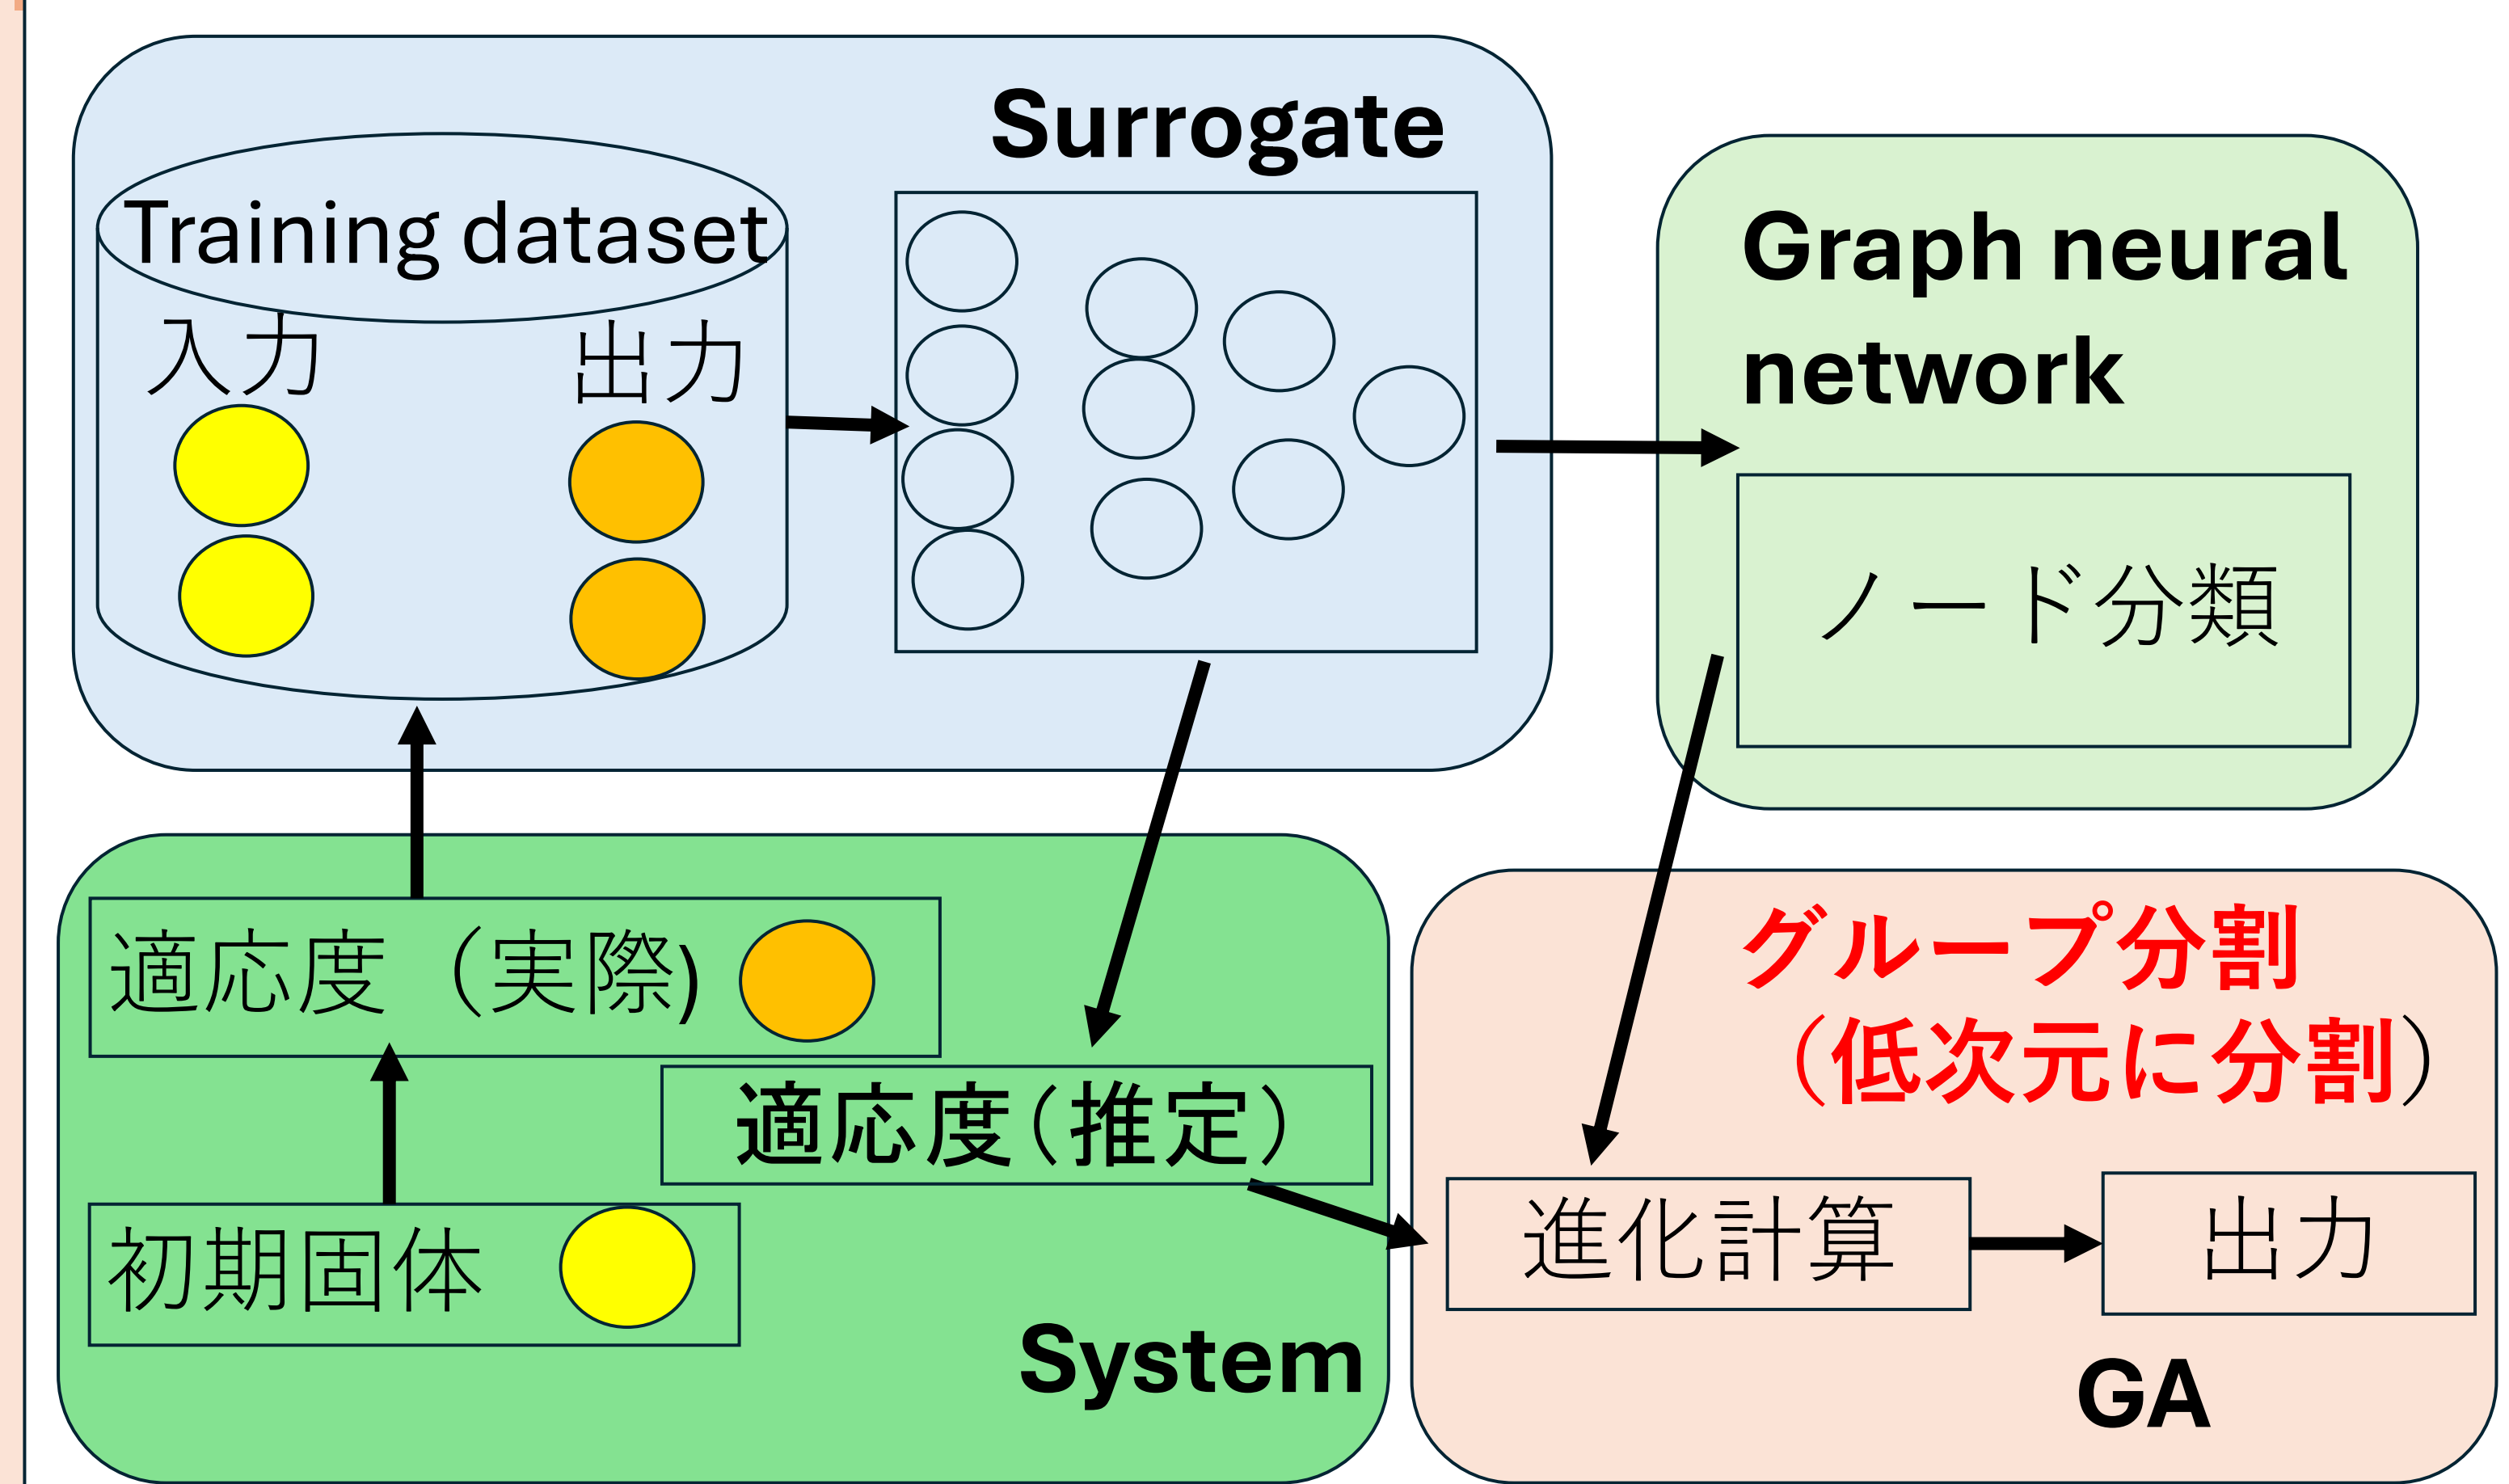


図4:提案手法の全体モデル

2.2研究の進捗

2.2.1実験環境

Rosenbrock(50次元)+Dixon(50次元)+Rosenbrock(50次元)




図5:Rosenbrock




図6:Dixon Function

$$f(x) = \sum_{i=1}^d \left[100(x_{i+1} - x_i^2)^2 + (x_i - 1)^2 \right] \quad (1)$$

$$f(x) = \sum_{i=1}^{d-1} (x_1 - 1)^2 + \sum_{i=2}^d i(2x_i^2 - x_{i-1})^2 \quad (2)$$

2.2.2実験結果

表1:実験結果

分割なし	分割あり
2.19e+09	<u>1.63e+09</u>

2.3 研究計画

- ・教師なしのクラスタリング
- ・グラフニューラルネットワーク精度向上

3参考文献

- [1]Kocijan, J., Stefan, I.J., Hvala, N., Zlata, P.M., d.o.o., B.M., Kocijan, J., Perne, M., Mlakar, P., Grašič, B., Marija, ., Božnar, Z., Kocijan, J., & d.o.o, M.Z. Surrogate modelling for the forecast of Seveso-type atmospheric pollutant dispersion.
[2] Wu, Z., Pan, S., Chen, F., Long, G., Zhang, C.Philip, S. Y. (2020). A comprehensive survey on graph neural networks. IEEE transactions on neural networks and learning systems, 32(1), 4-24.